Laboratorio 10

Proyecto de Consultoría — Predicción de Tripulación en Cruceros (PySpark)

- Sofia Mishell 22049
- Jose Marchena 22398

Contexto: Hyundai Heavy Industries solicita un modelo para **estimar la tripulación** requerida en nuevos cruceros a partir de características físicas y operativas del barco. **Datos:** barcos_crucero.csv con variables: *Cruise_line* (categórica), *Age, Tonnage, passengers, length, cabins, passenger_density* y **crew** (objetivo, en centenas de personas).

0) Iniciar Spark

```
In [292...
          import os
          ## Para funcionamiento en windows
          os.environ["SPARK_LOCAL_DIRS"] = r"C:\tmp\spark-temp"
          # (Crear la carpeta en tu equipo si no existe)
          from pyspark.sql import SparkSession
In [293...
          spark = SparkSession.builder.appName("Cruceros_Spark").getOrCreate()
          print("Spark version:", spark.version)
         Spark version: 4.0.1
In [294...
          data_df = spark.read.csv("./barcos_crucero.csv", header=True, inferSchema=True)
In [295...
          data_df.printSchema()
         root
          |-- Ship_name: string (nullable = true)
          |-- Cruise_line: string (nullable = true)
          |-- Age: integer (nullable = true)
          |-- Tonnage: double (nullable = true)
          |-- passengers: double (nullable = true)
          |-- length: double (nullable = true)
          |-- cabins: double (nullable = true)
          |-- passenger_density: double (nullable = true)
          |-- crew: double (nullable = true)
In [296...
          data_df.describe().show()
```

```
|summary|Ship name|Cruise line|
                                        Age
                                                      Tonnage
                                                                   passenge
            length|
                           cabins|passenger_density|
58
               158
                               158
                                               158
                                                               158
   mean | Infinity |
                      NULL | 15.689873417721518 | 71.28467088607599 | 18.457405063291
14|8.130632911392404| 8.830000000000005|39.90094936708861|7.794177215189873|
| stddev|
                      NULL | 7.615691058751413 | 37.229540025907866 | 9.6770947751434
            NULL
16 | 1.793473548054825 | 4.4714172221480615 | 8.63921711391542 | 3.503486564627034 |
    min|Adventure|
                    Azamara
                                                       2.329
                                                                        0.
                               0.33
    max|Zuiderdam|
                 Windstar
                                                       220.0
                                         48
4.0
              11.82
                               27.0
                                              71.43
                                                               21.0
```

1) Analisis Exploratorio

```
In [297...
           data_df.columns
Out[297...
           ['Ship_name',
             'Cruise_line',
             'Age',
             'Tonnage',
             'passengers',
             'length',
             'cabins',
             'passenger_density',
             'crew']
In [298...
           ## Categoricas: Ship Name y Cruise_line
           print(data_df.select("Ship_name").distinct().count())
           print(data_df.select("Cruise_line").distinct().count())
         138
         20
           Los nombres son casi todos unicos, de las 158 observaciones hay 138 nombres diferentes, lo
           que significa que solo 20 se repiten mas de una vez. Para la regresion se podria botar esta
```

columna

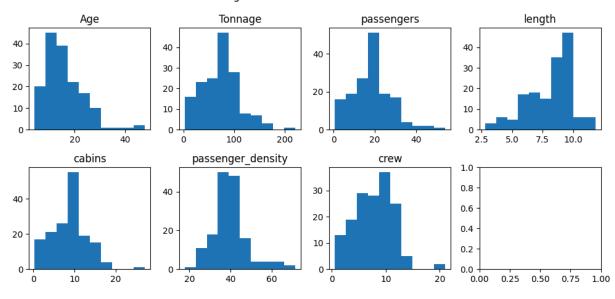
```
In [299...
          from pyspark.sql import functions as F
          ship_common_names = data_df.groupBy("Ship_name").count().orderBy(F.desc("count")).1
          ship_common_names.show()
```

```
+----+
     Cruise_line|count|
 ----+
  Royal_Caribbean 23
        Carnival 22
        Princess | 17|
| Holland_American| 14|
       Norwegian | 13
          Costa 11
       Celebrity 10
            MSC
                 8
            P&0
                  6
           Star
                  6
|Regent_Seven_Seas|
                  5
       Silversea
                  41
         Cunard
                  3 l
        Seabourn
                  3|
        Windstar
                  3 |
        Oceania|
                  3 |
        Crystal
                  2
         Disney
                  2
        Azamara
                  2
         Orient|
```

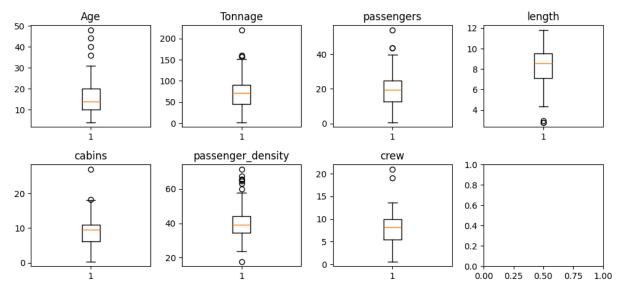
```
for i, c in enumerate(cols):
    axes[i].set_title(f"{c}")
    axes[i].hist(pandas_df[c])
plt.tight_layout()
plt.show()

# Boxplots
fig, ax = plt.subplots(2,4,figsize=(10,5))
fig.suptitle("Distribuciones - Cruceros")
axes = ax.flatten()
for i, c in enumerate(cols):
    axes[i].set_title(f"{c}")
    axes[i].boxplot(pandas_df[c])
plt.tight_layout()
plt.show()
```

Diagramas de frecuencias - Cruceros



Distribuciones - Cruceros

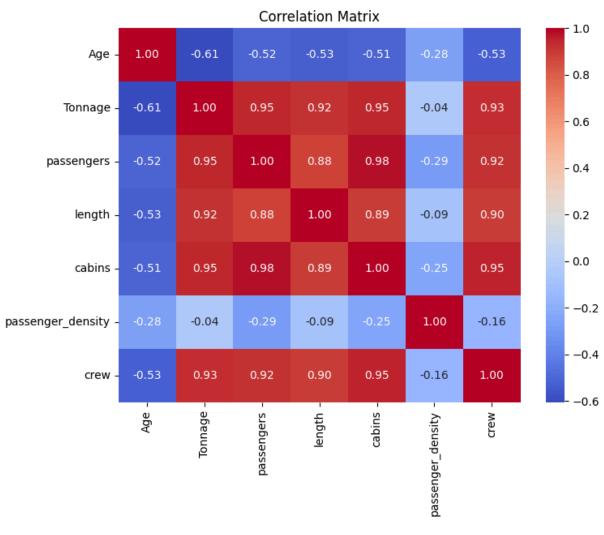


In [302...

import seaborn as sns
import matplotlib.pyplot as plt
from pyspark.sql.functions import col

```
cols = data_df.columns
cols.remove("Ship_name")
cols.remove("Cruise_line")

pdf = data_df.select(cols).toPandas()
corr = pdf.corr()
plt.figure(figsize=(8, 6))
sns.heatmap(corr, annot=True, fmt=".2f", cmap="coolwarm")
plt.title("Correlation Matrix")
plt.show()
```



2) Normalizacion

```
from pyspark.ml import Pipeline
from pyspark.ml.feature import StringIndexer, OneHotEncoder, VectorAssembler, Stand

cat_cols = ['Ship_name', 'Cruise_line']
num_cols = ['Age', 'Tonnage', 'passengers', 'length', 'cabins','passenger_density']
```

```
# 1 index categoricas
In [304...
          indexers = [
              StringIndexer(inputCol=col, outputCol=f"{col}_index", handleInvalid="keep")
              for col in cat cols
          # 2 OneHotEncoder para categoricas
          encoders = [
              OneHotEncoder(
                  inputCols=[f"{col}_index"],
                  outputCols=[f"{col}_encoded"]
              for col in cat_cols
          # 3 Standard scaler para numericas
          scaler = StandardScaler(
              inputCol="features_raw",
              outputCol="features_scaled",
              withMean=True,
              withStd=True
          ## Pipleine
          assembler = VectorAssembler(
              inputCols=[f"{col}_encoded" for col in cat_cols] + num_cols,
              outputCol="features_raw"
          pipeline = Pipeline(stages=indexers + encoders + [assembler, scaler])
```

3) Reg Lineal

Target -> "Crew"

Out[307... DataFrame[Ship_name: string, Cruise_line: string, Age: int, Tonnage: double, passe ngers: double, length: double, cabins: double, passenger_density: double, crew: do uble, Ship_name_index: double, Cruise_line_index: double, Ship_name_encoded: vector, Cruise_line_encoded: vector, features_raw: vector, features_scaled: vector]

Entrenar el modelo

```
In [308... # Crear modelo de regresión lineal
lr = LinearRegression(
    featuresCol="features_scaled",
    labelCol="crew",
    elasticNetParam=0.0, # Ridge
    regParam=0.3
)

# Entrenar
lr_model = lr.fit(train_df)

# Predicciones
predictions = lr_model.transform(test_df)
predictions.select("crew", "prediction").show(10)
```

Evaluar el modelo

```
mae = evaluator_mae.evaluate(predictions)

print(f"R2: {r2:.4f}")
print(f"RMSE: {rmse:.4f}")

print(f"MAE: {mae:.4f}")

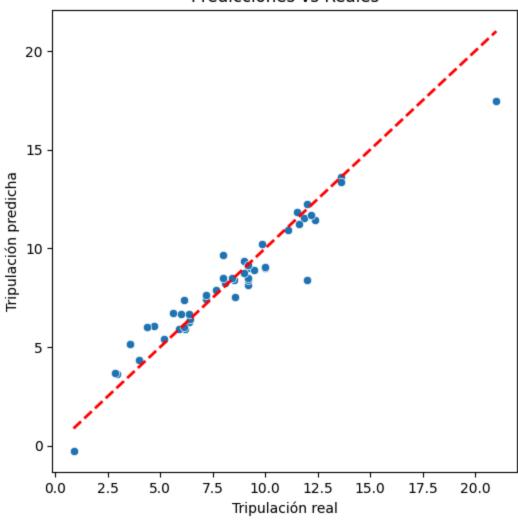
R2: 0.9125
RMSE: 1.0299
MAE: 0.6997

pred_pd = predictions.select("crew", "prediction").toPandas()

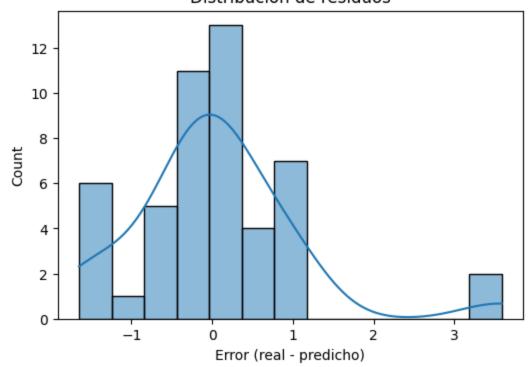
# Gráfico real vs predicho
plt figure(figsize=(6.6))
```

```
In [310...
          plt.figure(figsize=(6,6))
          sns.scatterplot(x="crew", y="prediction", data=pred_pd)
          plt.plot([pred_pd.crew.min(), pred_pd.crew.max()],
                    [pred_pd.crew.min(), pred_pd.crew.max()],
                    'r--', lw=2)
          plt.xlabel("Tripulación real")
          plt.ylabel("Tripulación predicha")
          plt.title("Predicciones vs Reales")
          plt.show()
          # Distribución de residuos
          plt.figure(figsize=(6,4))
          sns.histplot(pred_pd["crew"] - pred_pd["prediction"], kde=True)
          plt.title("Distribución de residuos")
          plt.xlabel("Error (real - predicho)")
          plt.show()
```





Distribución de residuos



Interpretación del modelo inicial

- Calidad del ajuste: R²≈0.91 indica que el modelo explica ~91% de la variabilidad de crew.
- Error: RMSE≈1.03 y MAE≈0.70 (en centenas de tripulantes) → errores promedio ~103 y
 70 personas, respectivamente.
- Signo de coeficientes (visión cualitativa):
 - Positivos: cabins, passengers, tonnage, length → al crecer el tamaño/capacidad, crece la tripulación.
 - Negativo: Age → barcos más antiguos tienden a requerir relativamente más personal de mantenimiento.
 - Dummies de Cruise_line: capturan diferencias operativas entre líneas.

3) Optimización (tuning) de hiperparámetros

Objetivo: mitigar multicolinealidad, mejorar generalización y reducir error. **Estrategia:** barrido de **regularización** con *Elastic Net* (combina L1+L2).

- regParam (λ): controla la magnitud de la penalización; valores más altos → coeficientes más pequeños (menos varianza, riesgo de subajuste).
- elasticNetParam (α): mezcla de penalizaciones:
 - α =0.0 (Ridge/L2): estabiliza coeficientes cuando hay multicolinealidad.
 - α = 1.0 (Lasso/L1): puede anular coeficientes (selección de variables).
 - α =0.5 (Elastic Net): balancea estabilidad (L2) y parsimonia (L1).

```
reg=0.1, alpha=0.0, R<sup>2</sup>=0.8987 reg=0.1, alpha=0.5, R<sup>2</sup>=0.9503 reg=0.1, alpha=1.0, R<sup>2</sup>=0.9468 reg=0.3, alpha=0.0, R<sup>2</sup>=0.9125 reg=0.3, alpha=0.5, R<sup>2</sup>=0.9412 reg=0.3, alpha=1.0, R<sup>2</sup>=0.9353 reg=0.5, alpha=0.0, R<sup>2</sup>=0.9101 reg=0.5, alpha=0.5, R<sup>2</sup>=0.9218 reg=0.7, alpha=1.0, R<sup>2</sup>=0.9218 reg=0.7, alpha=0.0, R<sup>2</sup>=0.9054 reg=0.7, alpha=0.5, R<sup>2</sup>=0.9210 reg=0.7, alpha=1.0, R<sup>2</sup>=0.9047
```

Resultados del barrido (R² en test)

α (elasticNetParam)	Tipo	R ²	
0.0	Ridge	0.8987	
0.5	Elastic Net	0.9503	
1.0	Lasso	0.9468	
0.0	Ridge	0.9125	
0.5	Elastic Net	0.9412	
1.0	Lasso	0.9353	
0.0	Ridge	0.9101	
0.5	Elastic Net	0.9318	
1.0	Lasso	0.9218	
0.0	Ridge	0.9054	
0.5	Elastic Net	0.9210	
1.0	Lasso	0.9047	
	0.0 0.5 1.0 0.5 1.0 0.5 1.0 0.0 0	0.0 Ridge 0.5 Elastic Net 1.0 Lasso 0.5 Elastic Net 1.0 Lasso 0.5 Elastic Net 1.0 Lasso 0.5 Elastic Net	

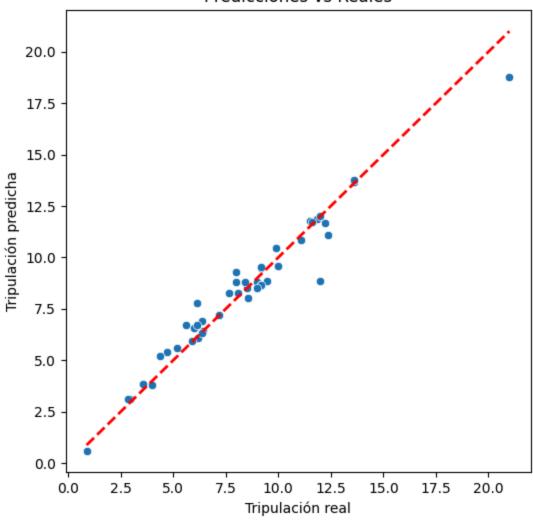
Lectura:

- Penalización moderada (regParam=0.1) + mezcla L1/L2 (α=0.5) dio el mejor equilibrio entre sesgo y varianza.
- Con α=0.5 , el modelo controla multicolinealidad **sin** descartar en exceso predictores útiles (como sí podría ocurrir con Lasso puro).

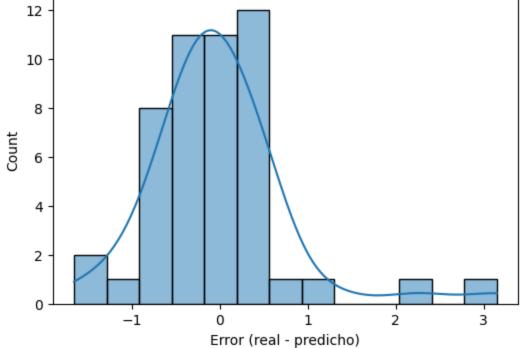
```
In [312... # Crear modelo de regresión lineal
lr = LinearRegression(
    featuresCol="features_scaled",
    labelCol="crew",
    elasticNetParam=0.5, # Ridge
    regParam=0.1
)
```

```
# Entrenar
          lr_model = lr.fit(train_df)
          # Predicciones
          predictions = lr_model.transform(test_df)
          predictions.select("crew", "prediction").show(10)
        +----+
                     prediction
        +----+
         |11.85|11.868998103092443|
          6.0 | 6.569276869196921 |
          5.2 | 5.600445669330788 |
          9.2 | 9.503949046784376 |
          8.5 | 8.499492486736475 |
         8.58 8.036886915788687
         6.17 6.067176306343802
          4.7 | 5.3917094767129905 |
         12.0 | 12.028691583889225 |
          9.0 | 8.805780520498772 |
         +----+
        only showing top 10 rows
In [313... r2 = evaluator_r2.evaluate(predictions)
          rmse = evaluator_rmse.evaluate(predictions)
          mae = evaluator_mae.evaluate(predictions)
          print(f"R2: {r2:.4f}")
          print(f"RMSE: {rmse:.4f}")
          print(f"MAE: {mae:.4f}")
        R2: 0.9503
        RMSE: 0.7763
        MAE: 0.5156
         pred_pd = predictions.select("crew", "prediction").toPandas()
In [314...
          # Gráfico real vs predicho
          plt.figure(figsize=(6,6))
          sns.scatterplot(x="crew", y="prediction", data=pred_pd)
          plt.plot([pred_pd.crew.min(), pred_pd.crew.max()],
                   [pred_pd.crew.min(), pred_pd.crew.max()],
                   'r--', 1w=2)
          plt.xlabel("Tripulación real")
          plt.ylabel("Tripulación predicha")
          plt.title("Predicciones vs Reales")
          plt.show()
          # Distribución de residuos
          plt.figure(figsize=(6,4))
          sns.histplot(pred_pd["crew"] - pred_pd["prediction"], kde=True)
          plt.title("Distribución de residuos")
          plt.xlabel("Error (real - predicho)")
          plt.show()
```









Comparación antes vs después

Modelo	R ²	RMSE	MAE
Inicial (Ridge, λ =0.3, α =0.0)	0.9125	1.0299	0.6997
Final (Elastic Net, λ =0.1, α =0.5)	0.9503	0.7763	0.5156

Mejoras:

- \uparrow R²: +0.0378 (de 0.9125 a 0.9503). Si se compara el **error no explicado** (1-R²), se reduce de **0.0875** a **0.0497** \rightarrow **-43**% de varianza no explicada.
- \downarrow **RMSE:** $-0.2536 \rightarrow -24.6\%$ (de 1.0299 a 0.7763).
- \downarrow **MAE:** $-0.1841 \rightarrow -26.3\%$ (de 0.6997 a 0.5156).

¿Por qué este es el mejor modelo?

- Colinealidad controlada: L2 estabiliza coeficientes entre passengers, cabins y tonnage.
- Parcimonia sin pérdida de señal: L1 atenúa/descarta ruido en dummies de *Cruise_line* y variables menos informativas, sin "vaciar" el modelo.
- **Generalización superior:** mejores métricas en test y residuos centrados en 0 (sin sesgo sistemático).
- **Coherencia con EDA:** variables clave coinciden con las correlaciones altas observadas; Age mantiene efecto negativo coherente.

5) Conclusiones para negocio

- El modelo final (Elastic Net) explica ~95% de la variabilidad del tamaño de la tripulación y reduce el error en ~25% respecto al modelo inicial.
- Las variables más influyentes son cabins , passengers y tonnage ; length también aporta; Age presenta efecto negativo; Cruise_line ajusta diferencias operativas.
- Usos recomendados: estimaciones tempranas de tripulación en etapas de diseño, planeación de costos y dotación de personal.

Resultado final: Modelo Elastic Net (λ =0.1, α =0.5) en PySpark con R²=0.9503, RMSE=0.7763, MAE=0.5156. Desempeño robusto, interpretable y alineado con los patrones del EDA.